

Evaluación Parcial N°2

Encargo con Presentación

Docente

Sigla	Nombre Asignatura	Tiempo Asignado	% Ponderación
SCY1101	Programación para la Ciencia de Datos	2 semanas	30%

1.Instrucciones generales

Descripción

- Esta evaluación busca que el estudiante experimente el ciclo completo de desarrollo de una solución de machine learning orientada a un problema de negocio real.
- Cada equipo deberá integrar modelos supervisados y no supervisados, realizar comparación rigurosa y optimización, y documentar su justificación técnica y análisis experimental.
- El foco está en que los estudiantes seleccionen, implementen, evalúen y optimicen distintos modelos, aplicando las mejores prácticas de ingeniería de datos y machine learning.
- Además, se promueve el razonamiento crítico, la argumentación y la capacidad de comunicar resultados técnicos a través de informes y presentaciones.
- La distribución de los porcentajes en esta evaluación es la siguiente:

Evaluación	Tipo de situación evaluativa	Distribución de porcentajes en el ET	Individual/Grupal
Evaluación sumativa II/ Evaluación Parcial N°2	Encargo	10%	Grupal
	Presentación	20%	Individual
Total		30%	

- El **tiempo** asignado para desarrollar esta evaluación en el laboratorio es de **2 semanas para el encargo y 15 minutos** para la presentación y se realiza de manera **(individual, parejas o equipos)**.

Instrucciones específicas de la Evaluación:**Ítem I: Consideraciones para el encargo (Grupal):**

Focos de observación:

- Organización y reproducibilidad del proyecto.
- Calidad técnica en la implementación de modelos y pipelines.
- Profundidad y rigor del análisis experimental.
- Justificación y claridad en la elección de algoritmos y técnicas.

El entregable debe incluir:

1. Estructura de carpetas y archivos

Se recomienda la siguiente organización en una carpeta raíz (proyecto_modelado/):

notebooks/

- 01_exploratory_analysis.ipynb: Análisis exploratorio de los datos, visualizaciones y detección de patrones.
- 02_supervised_modeling.ipynb: Implementación de modelos supervisados (clasificación/regresión) con Scikit-learn.
- 03_model_evaluation.ipynb: Evaluación comparativa, métricas, interpretación de resultados.
- 04_hyperparameter_optimization.ipynb: Optimización de hiperparámetros (GridSearchCV/RandomizedSearchCV), documentación de resultados.
- 05_final_analysis.ipynb: Integración y análisis final.
- src/
 - data_preprocessing.py: Funciones de limpieza, transformación y preparación de datos.
 - model_training.py: Definición y entrenamiento de modelos.
 - model_evaluation.py: Funciones de evaluación y comparación.
 - hyperparameter_tuning.py: Funciones para optimización de hiperparámetros.
- models/trained_models/: Modelos entrenados serializados.
- results/metrics/, plots/, reports/: Métricas, visualizaciones y reportes.
- README.md: Guía de uso del proyecto y dependencias.

2. Informe técnico (12-15 páginas):

- Resumen ejecutivo: Descripción general, objetivo y resultados principales.
- Marco metodológico: Justificación de la selección de algoritmos y técnicas empleadas.
- Análisis experimental: Descripción detallada de experimentos, datos usados y configuraciones.
- Resultados y comparación de modelos: Reporte de métricas, tablas y gráficos comparativos.
- Optimización de hiperparámetros: Proceso seguido, justificación de los métodos y análisis del impacto.
- Conclusiones y recomendaciones: Reflexión sobre resultados, dificultades, alternativas evaluadas y recomendaciones futuras.
- Referencias: Bibliografía utilizada.

3. Aspectos formales del código y reproducibilidad

- Código limpio, modular y documentado (incluyendo docstrings).
- Manejo robusto de excepciones y validación de entradas.
- Uso eficiente de recursos computacionales (uso de seeds, random_state, evitar procesamiento innecesario).
- Entregable debe ser 100% reproducible.
- Uso de Scikit-learn, pandas, numpy, matplotlib/seaborn y buenas prácticas de ML.

Ítem II: Consideraciones para la Presentación:**Focos de observación:**

- Dominio conceptual sobre selección, implementación, evaluación y optimización de modelos.
- Capacidad de explicar decisiones técnicas y metodológicas con argumentos claros y ejemplos concretos.
- Claridad al interpretar y comparar métricas de evaluación.
- Uso de visualizaciones efectivas y comunicación científica.

La presentación individual debe incluir:

- Justificación del enfoque y selección de modelos: Argumentación sobre la elección de algoritmos supervisados/no supervisados y su pertinencia según el problema.
- Demostración y explicación de resultados clave: Explicación de los hallazgos principales, interpretación de resultados y discusión de implicancias.
- Comparación de métricas y visualizaciones: Análisis comparativo entre modelos, interpretación de métricas, trade-offs y visualizaciones relevantes.
- Explicación del proceso de optimización de hiperparámetros y su impacto: Descripción detallada del procedimiento de optimización, análisis de los cambios obtenidos y reflexiones sobre mejoras potenciales.
- Recomendaciones y lecciones aprendidas: Reflexión sobre el proceso de modelado, dificultades encontradas, mejoras sugeridas y aprendizajes adquiridos.

Aspectos formales:

- Slides claros, notebooks ejecutables o dashboards como apoyo visual.
- Uso de lenguaje técnico adecuado, argumentación sólida y ejemplos concretos.
- Todos los estudiantes deben participar en la defensa.

2. Pauta de Evaluación

Categoría	% logro	Descripción niveles de logro
Muy buen desempeño	100%	Demuestra un desempeño destacado, evidenciando el logro de todos los aspectos evaluados en el indicador.
Buen desempeño	80%	Demuestra un alto desempeño del indicador, presentando pequeñas omisiones, dificultades y/o errores.
Desempeño aceptable	60%	Demuestra un desempeño competente, evidenciando el logro de los elementos básicos del indicador, pero con omisiones, dificultades o errores.
Desempeño incipiente	30%	Presenta importantes omisiones, dificultades o errores en el desempeño, que no permiten evidenciar los elementos básicos del logro del indicador, por lo que no puede ser considerado competente.
Desempeño no logrado	0%	Presenta ausencia o incorrecto desempeño.

Indicador de Evaluación	Categorías de Respuesta					Ponderación Indicador de Evaluación
	Muy buen desempeño 100%	Buen desempeño 80%	Desempeño aceptable 60%	Desempeño incipiente 30%	Desempeño no logrado 0%	
Dimensión: Encargo						
1. IEE 2.1.1: Implementa múltiples modelos de clasificación y regresión usando Scikit-learn con configuraciones apropiadas y justificación técnica sólida	Implementa y configura múltiples modelos con pipelines, justifica técnicamente cada decisión y demuestra dominio de Scikit-learn	Implementa y configura modelos principales con pipelines básicos, buena justificación	Implementa modelos básicos con configuración simple, justificación superficial	Implementa algunos modelos con errores y sin justificación clara	No implementa correctamente los modelos o el código no ejecuta	20%

2. IEE 2.1.2: Aplica técnicas de aprendizaje no supervisado (clustering, reducción de dimensionalidad) para exploración y análisis de datos	Realiza validación cruzada robusta, calcula todas las métricas clave, compara y visualiza resultados con análisis avanzado	Realiza validación cruzada adecuada y métricas principales, comparación básica	Realiza validación cruzada simple y algunas métricas, comparación superficial	Validación cruzada incompleta, pocas métricas, sin análisis comparativo	No evalúa correctamente o hay errores graves	20%
3. IEE 2.2.1: Evalúa modelos usando validación cruzada, implementando múltiples métricas de rendimiento e interpretando resultados comparativamente	Implementa optimización exhaustiva y justifica técnica y visualmente el proceso y sus efectos	Optimización adecuada con justificación suficiente	Optimización básica, justificación elemental	Optimización incompleta o sin justificación	No realiza optimización o hay errores graves	30%
4. IEE 2.3.1: Optimiza hiperparámetros usando GridSearchCV y RandomizedSearchCV, documentando el proceso y analizando el impacto en el rendimiento	Aplica múltiples técnicas no supervisadas, selecciona y evalúa con métricas y visualizaciones avanzadas	Aplica técnicas principales y métricas básicas, visualización suficiente	Aplica solo técnicas estándar, visualización simple	Técnicas no supervisadas incompletas o con errores	No aplica técnicas o hay errores graves	30%
Dimensión: Presentación						
5. IEP 2.1.3: Explica la implementación de modelos supervisados, justificando la selección de algoritmos según la naturaleza del problema	Explica y justifica todas las decisiones técnicas con argumentos sólidos y	Explica bien la mayoría de las decisiones, con justificación suficiente	Explica lo esencial, justificación superficial	Explicación incompleta o poco técnica	No explica o es incorrecta	30%

	ejemplos claros					
6. IEP 2.2.2: Interpreta y compara métricas de evaluación, explicando el significado de cada métrica en el contexto del problema específico	Interpreta todas las métricas relevantes, compara modelos y explica trade-offs con visualizaciones avanzadas	Interpreta métricas principales y compara modelos, explicación suficiente	Interpreta algunas métricas, comparación superficial	Interpretación incompleta, sin visualización adecuada	No interpreta o lo hace incorrectamente	35%
7. IEP 2.3.2: Explica el proceso de optimización de hiperparámetros y su impacto en el rendimiento final de los modelos	Explica el proceso completo, describe y analiza impacto con claridad y propuestas de mejora	Explica proceso y análisis principal, conclusiones suficientes	Explicación básica del proceso, análisis superficial	Explicación incompleta o errónea	No explica o es incorrecto	35%
Total						100%